



BUSCASAM

**Descubrimiento de la producción académica de la UNSAM
mediante búsqueda híbrida semántica**

Trabajo Práctico Final Integrador — Ingeniería de Software

Licenciatura en Ciencia de Datos, UNSAM — Grupo 11

Lucas Achaval

lachavalrodriguez@estudiantes.unsam.edu.ar

Nicolás Cirulli

ncirulli@unsam-bue.edu.ar

Marcos Achaval

machavalrodriguez@unsam-bue.edu.ar

Matías Raina

meraina@estudiantes.unsam.edu.ar

Resumen Ejecutivo

El Diagnóstico

Producción académica valiosa de la UNSAM dispersa e inaccesible. El conocimiento no circula.

La Solución

BUSCASAM es una plataforma web para publicar y encontrar trabajos de forma ágil y centralizada.

El Diferencial: Búsqueda Híbrida

Combina similitud semántica con coincidencia léxica tradicional.

Entiende la **intención** de la consulta en lenguaje natural, sin limitarse a palabras clave exactas.

La Situación Actual

Producción académica fragmentada e inaccesible entre unidades académicas.

Impacto del Status Quo

- **Redundancia:** Temas duplicados por desconocimiento.
- **Pérdida de valor:** El conocimiento de grado no se acumula.
- **Desconexión:** Sector productivo sin canal de transferencia.

Tres Síntomas Clave

- **Invisibilidad:** RI-UNSAM aloja tesis formales, pero excluye trabajos de grado.
- **Fricción:** Búsquedas tradicionales exigen términos exactos.
Ej: «identificar flores por medidas»
- **Desconexión externa:** Falta de un portal unificado de capacidades.

Propuesta de Solución: BUSCASAM

Propósito de la Plataforma

Publicación ágil y búsqueda semántica en un único portal integrado.

Público Objetivo

- **Estudiantes:** Carga guiada y consulta de trabajos previos.
- **Docentes e Investigadores:** Búsqueda, coautoría y moderación.
- **Empresas / Externos:** Acceso y descubrimiento de talento.

Capacidades Clave

- **Búsqueda Híbrida:** Fusión semántica y léxica.
- **Ingesta Asistida:** OCR para escaneos, extracción automática y sugerencias por IA.
- **Visibilidad Granular:** Accesos público, institucional o privado.
- **Moderación Activa:** Panel para gestión de reportes y contenidos.

Impacto Esperado y Beneficios

Beneficios Clave

- **Ahorro de Tiempo:** Buscador único que reemplaza repositorios fragmentados.
- **Visibilidad:** Los trabajos de grado circulan en la comunidad universitaria.
- **Vinculación:** Vitrina de perfiles para conectar talento con empresas.

Diferencial Competitivo

- **Alcance Completo:** Desde apuntes y monografías hasta tesis.
- **Búsqueda Semántica:** Entiende la intención detrás del texto.
- **Autogestión:** Carga directa por el autor en minutos.

Plan de Pruebas

Estrategia de Verificación

- **Pruebas Unitarias:** Lógica de ranking híbrido y pipeline de datos.
- **Pruebas de Integración:** Cobertura de endpoints API y persistencia en base de datos.
- **Pruebas E2E:** Flujos de usuario automatizados en navegador (login, búsqueda, reporte).

Pruebas No Funcionales y CI/CD

- **Seguridad:** Control automatizado de filtrado de roles y visibilidad.
- **Resiliencia:** Caída del motor semántico y degradación elegante a búsqueda léxica.
- **Integración Continua:** Bloqueo de ramas si fallan pruebas o auditorías de dependencias.

Registro de Riesgos Clave

#	Tipo	Riesgo	Prob.	Imp.	Mitigación Principal
R1	Negocio	Contenido semilla insuficiente	Alta	Alto	Carga inicial y campaña activa con cátedras.
R2	Técnico	Ranking híbrido poco relevante	Media	Alto	Calibración de umbrales + búsqueda léxica.
R3	Proyecto	Inexperiencia / retrasos con embeddings	Alta	Medio	POC temprana + holgura en planificación.
R4	Técnico	PDFs escaneados o malformados	Media	Medio	Ingesta con OCR + reintentos automáticos.
R5	Negocio	Contenido inadecuado / ofensivo	Media	Medio	Reportes y moderación por panel docente.

Indicadores de Éxito y Metas

Indicador	Forma de Cálculo y Meta
Trabajos publicados por unidad	Conteo mensual de documentos por escuela/área.
Tasa de éxito de búsqueda	Sesiones con clic $\div$ total de búsquedas (Meta: $> 60\%$).
Latencia p95 de búsqueda	Percentil 95 del tiempo de respuesta (Meta: < 2 s).
Lecturas semanales	Visualizaciones únicas deduplicadas (ventana de 7 días).
Satisfacción de usuarios	Encuesta semestral a alumnos/docentes (Meta: $\geq 70\%$ puntaje 4 o 5).

Los Cuatro Componentes

1. **Frontend (Next.js):** Interfaz responsiva.
2. **API REST (FastAPI):** Negocio, autenticación y accesos.
3. **Persistencia (PostgreSQL):** Almacén de datos.
4. **Embeddings:** Generación local en CPU.

Decisión Arquitectónica Clave

Despliegue unificado en una única VM de GCP (bajo costo y baja complejidad).

Servicios externos (Google OAuth / Vertex AI) desacoplados y opcionales.


Arquitectura de Referencia

Flujo de Peticiones

- **Acceso HTTPS:**
Balanceador de carga
GCP redirige a Nginx.
- **Proxy Inverso:** Nginx
deriva tráfico a Next.js
(Web) o FastAPI (API).
- **Workers:** Cola asíncrona
para OCR y embeddings.

Servicios Externos

Google OAuth y Vertex AI
integrados de forma
desacoplada.



Decisiones de Diseño y Calidad

PostgreSQL Multi-rol

Unificación de transacciones, búsqueda full-text, pgvector y colas de tareas.

Mínima superficie operativa → alta mantenibilidad y respaldos simplificados.

Atributos de Calidad Clave

- **Seguridad:** Filtrado estricto de visibilidad por rol en todas las capas.
- **Confiabilidad:** Degradación controlada a búsqueda léxica ante fallas del servicio vectorial.

Plan de Trabajo y Costos Mensuales

Cronograma de Fases

Fase	Alcance	Sem.
F0–F1	Arquitectura y Acceso	1–2
F2	Búsqueda Híbrida Semántica	3–4
F3–F4	Publicación y Detalle	5–6
F5–F6	Colaboración y Moderación	7–8
F7–F8	Descubrimiento y Producción	8–9

- **Ciclo Rápido:** Construcción en 2 semanas usando asistencia de IA agéntica.

Costos Mensuales de Operación

Concepto	USD/mes
Máquina virtual (2 vCPU, 8 GB)	~50
Disco persistente (50 GB)	~5
Balanceador HTTPS	~20
Red, registros, backups diarios	~8
IA para resúmenes (Gemini API / Vertex)	< 5
Dominio (prorrateado)	~1
Total Estimado	~90

Conclusiones y Recomendaciones

Síntesis

Resuelve la fragmentación académica de la UNSAM. Plataforma viable y escalable por un costo base de **USD 90/mes**.

Próximos Pasos Recomendados

1. **Piloto:** Implementación en una unidad académica para medir la adopción.
2. **Fase 2:** Favoritos y recomendaciones basados en el piloto.
3. **Vinculación:** Radar de talento para el sector productivo.
4. **Institucionalización:** Integración formal con la biblioteca.



BUSCASAM

Descubrimiento de la producción académica de la UNSAM

¡Muchas gracias!

buscasam.org

Grupo 11 — Ingeniería de Software