



# BUSCASAM

**Descubrimiento de la producción académica de la UNSAM  
mediante búsqueda híbrida semántica**

---

**Trabajo Práctico Final Integrador — Ingeniería de Software**

Licenciatura en Ciencia de Datos, UNSAM — Grupo 11

**Lucas Achaval**

lachavalrodriguez@estudiantes.unsam.edu.ar

**Nicolás Cirulli**

nlcirulli@unsam-bue.edu.ar

**Marcos Achaval**

machavalrodriguez@unsam-bue.edu.ar

**Matías Raina**

meraina@estudiantes.unsam.edu.ar

# Resumen Ejecutivo

---

## El Diagnóstico

Producción académica valiosa de la UNSAM dispersa e inaccesible. El conocimiento no circula.

## La Solución

**BUSCASAM** es una plataforma web para publicar y encontrar trabajos de forma ágil y centralizada.

## El Diferencial: Búsqueda Híbrida

Combina similitud semántica con coincidencia léxica tradicional.

Entiende la **intención** de la consulta en lenguaje natural, sin limitarse a palabras clave exactas.

# Contexto y Diagnóstico

---

## La Situación Actual

Producción académica fragmentada e inaccesible entre unidades académicas.

## Impacto del Status Quo

- **Redundancia:** Temas duplicados por desconocimiento.
- **Pérdida de valor:** El conocimiento de grado no se acumula.
- **Desconexión:** Sector productivo sin canal de transferencia.

## Tres Síntomas Clave

- **Invisibilidad:** RI-UNSAM aloja tesis formales, pero excluye trabajos de grado.
- **Fricción:** Búsquedas tradicionales exigen términos exactos.  
Ej: «identificar flores por medidas»
- **Desconexión externa:** Falta de un portal unificado de capacidades.

# Propuesta de Solución: BUSCASAM

---

## Propósito de la Plataforma

Publicación ágil y búsqueda semántica en un único portal integrado.

## Público Objetivo

- **Estudiantes:** Carga guiada y consulta de trabajos previos.
- **Docentes e Investigadores:** Búsqueda, coautoría y moderación.
- **Empresas / Externos:** Acceso y descubrimiento de talento.

## Capacidades Clave

- **Búsqueda Híbrida:** Fusión semántica y léxica.
- **Ingesta Asistida:** OCR para escaneos, extracción automática y sugerencias por IA.
- **Visibilidad Granular:** Accesos público, institucional o privado.
- **Moderación Activa:** Panel para gestión de reportes y contenidos.

# Impacto Esperado y Beneficios

---

## Beneficios Clave

- **Ahorro de Tiempo:** Buscador único que reemplaza repositorios fragmentados.
- **Visibilidad:** Los trabajos de grado circulan en la comunidad universitaria.
- **Vinculación:** Vitrina de perfiles para conectar talento con empresas.

## Diferencial Competitivo

- **Alcance Completo:** Desde apuntes y monografías hasta tesis.
- **Búsqueda Semántica:** Entiende la intención detrás del texto.
- **Autogestión:** Carga directa por el autor en minutos.

## Estrategia de Verificación

- **Pruebas Unitarias:** Lógica de ranking híbrido y pipeline de datos.
- **Pruebas de Integración:** Cobertura de endpoints API y persistencia en base de datos.
- **Pruebas E2E:** Flujos de usuario automatizados en navegador (login, búsqueda, reporte).

## Pruebas No Funcionales y CI/CD

- **Seguridad:** Control automatizado de filtrado de roles y visibilidad.
- **Resiliencia:** Caída del motor semántico y degradación elegante a búsqueda léxica.
- **Integración Continua:** Bloqueo de ramas si fallan pruebas o auditorías de dependencias.

## Registro de Riesgos Clave

| #  | Tipo    | Riesgo                          | Prob. | Imp.  | Mitigación Principal                         |
|----|---------|---------------------------------|-------|-------|----------------------------------------------|
| R1 | Negocio | Contenido semilla insuficiente  | Alta  | Alto  | Carga inicial y campaña activa con cátedras. |
| R2 | Negocio | Contenido inadecuado / ofensivo | Media | Medio | Reportes y moderación por panel docente.     |

## Indicadores de Éxito y Metas

---

| Indicador                             | Forma de Cálculo y Meta                                        |
|---------------------------------------|----------------------------------------------------------------|
| <b>Trabajos publicados por unidad</b> | Conteo mensual de documentos por escuela/área.                 |
| <b>Tasa de éxito de búsqueda</b>      | Sesiones con clic $\div$ total de búsquedas (Meta: $> 60\%$ ). |
| <b>Latencia p95 de búsqueda</b>       | Percentil 95 del tiempo de respuesta (Meta: $< 2$ s).          |



## Los Cuatro Componentes

1. **Frontend (Next.js):** Interfaz responsiva.
2. **API REST (FastAPI):** Negocio, autenticación y accesos.
3. **Persistencia (PostgreSQL):** Almacén de datos.
4. **Embeddings:** Generación local en CPU.


# Arquitectura de Referencia

## Flujo de Peticiones

- **Acceso HTTPS:**  
Balanceador de carga  
GCP redirige a Nginx.
- **Proxy Inverso:** Nginx  
deriva tráfico a Next.js  
(Web) o FastAPI (API).
- **Workers:** Cola asíncrona  
para OCR y embeddings.

## Servicios Externos

Google OAuth y Vertex AI  
integrados de forma  
desacoplada.



# Decisiones de Diseño y Calidad

---

## PostgreSQL Multi-rol

Unificación de transacciones, búsqueda full-text, pgvector y colas de tareas.

Mínima superficie operativa → alta mantenibilidad y respaldos simplificados.

## Atributos de Calidad Clave

- **Seguridad:** Filtrado estricto de visibilidad por rol en todas las capas.
- **Confiabilidad:** Degradación controlada a búsqueda léxica ante fallas del servicio vectorial.

# Plan de Trabajo y Costos Mensuales

## Cronograma de Fases

| Fase  | Alcance                     | Sem. |
|-------|-----------------------------|------|
| F0–F1 | Arquitectura y Acceso       | 1–2  |
| F2    | Búsqueda Híbrida Semántica  | 3–4  |
| F3–F4 | Publicación y Detalle       | 5–6  |
| F5–F6 | Colaboración y Moderación   | 7–8  |
| F7–F8 | Descubrimiento y Producción | 8–9  |

- **Ciclo Rápido:** Construcción en 2 semanas usando asistencia de IA agéntica.

## Costos Mensuales de Operación

| Concepto                                | USD/mes    |
|-----------------------------------------|------------|
| Máquina virtual (2 vCPU, 8 GB)          | ~50        |
| Disco persistente (50 GB)               | ~5         |
| Balanceador HTTPS                       | ~20        |
| Red, registros, backups diarios         | ~8         |
| IA para resúmenes (Gemini API / Vertex) | < 5        |
| Dominio (prorrateado)                   | ~1         |
| <b>Total Estimado</b>                   | <b>~90</b> |

# Conclusiones y Recomendaciones

---

## Síntesis

Resuelve la fragmentación académica de la UNSAM. Plataforma viable y escalable por un costo base de **USD 90/mes**.

## Próximos Pasos Recomendados

1. **Piloto:** Implementación en una unidad académica para medir la adopción.
2. **Fase 2:** Favoritos y recomendaciones basados en el piloto.
3. **Vinculación:** Radar de talento para el sector productivo.
4. **Institucionalización:** Integración formal con la biblioteca.



# BUSCASAM

Descubrimiento de la producción académica de la UNSAM

---

**¡Muchas gracias!**

[buscasam.org](https://buscasam.org)

Grupo 11 — Ingeniería de Software